Teoría de Aprendizaje de Máquina

Parcial 1 – 2026-2

Desarrollo matemático completo

Regresión, RKHS, MMD y correlación de Pearson

Samuel Elias Gómez - Sebastián Tovar

Este documento desarrolla paso a paso los puntos 1.1–1.5, 2.1–2.4 y 3.1–3.2 del enunciado. Se incluyen definiciones, dimensiones, justificaciones de las identidades matriciales, interpretaciones y código Python de referencia.

Material de estudio y desarrollo matemático

14 de octubre de 2026

Índice

Notación y convenciones generales **2**

I Regresión en espacios de características **2**

1. Planteamiento del modelo **2**

1.1. Mínimos cuadrados . . . 3
1.2. Mínimos cuadrados regularizados . . . 3
1.3. Máxima verosimilitud . . . 4
1.4. Máximo a posteriori (MAP) . . . 5
1.5. Implementación y análisis en Python . . . 6

II Espacios RKHS, embeddings de media y MMD **7**

2. Conceptos previos: kernel, mapa de características y RKHS **7**

2.1. Definición rigurosa del embedding de media . . . 8
2.2. Por qué $\mu_k \in \mathcal{H}_k$ y su interpretación geométrica . . . 8
2.3. Discrepancia máxima de medias (MMD) . . . 9
2.4. Implementación con MNIST y Fashion-MNIST . . . 11

III Correlación de Pearson **13**

3. Correlación de Pearson: espacio original y RKHS **13**

3.1. Coeficiente de Pearson en el espacio original . . . 13
3.2. Alineamiento centrado de kernels en RKHS . . . 14

Resumen de resultados y errores conceptuales que conviene evitar **17**

Notación y convenciones generales

- N es el número de observaciones; P es la dimensión de la entrada original; Q es el número de características explícitas.
- Los vectores de observaciones y respuestas se consideran columnas. La matriz de diseño $\Phi \in \mathbb{R}^{N\times Q}$ tiene la observación n en la fila n.
- I_N denota la identidad $N \times N$ y $\mathbf{1}_N$ es el vector de unos de dimensión $N \times 1$.
- $\mathcal{X}$ denota el dominio de los datos; X en mayúscula denota una variable aleatoria con valores en ese dominio; x en minúscula denota una realización concreta.
- $\mathcal{H}_k$ es el espacio de Hilbert con núcleo reproductor asociado a k. No debe confundirse con la matriz de centrado H que se usa en el punto 3.

Concepto clave

Diferencia de notación importante. El símbolo $\mathcal{H}_k$ representa un espacio funcional (el RKHS asociado al kernel); en cambio, $H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$ es una matriz finita que centra datos o matrices de Gram. Son objetos distintos aunque compartan la letra H.

Parte I

Regresión en espacios de características

1. Planteamiento del modelo

Se dispone de datos $\{(x_n, t_n)\}_{n=1}^N$, con $x_n \in \mathbb{R}^P$ y $t_n \in \mathbb{R}$. Se aplica una transformación explícita

$$\phi : \mathbb{R}^P \longrightarrow \mathbb{R}^Q, \qquad \phi(x_n) = \begin{bmatrix}\phi_1(x_n) & \cdots & \phi_Q(x_n)\end{bmatrix}^\top,$$

y se propone el modelo lineal en el espacio de características

$$t_n = \phi(x_n)^\top w + \eta_n, \qquad w \in \mathbb{R}^Q.$$

Al apilar las observaciones se obtiene

$$t = \Phi w + \eta, \quad \Phi = \begin{bmatrix}\phi(x_1)^\top \\ \vdots \\ \phi(x_N)^\top\end{bmatrix} \in \mathbb{R}^{N\times Q}, \quad t, \eta \in \mathbb{R}^N.$$

Intuición

Aunque el modelo sea lineal respecto a w, no tiene por qué ser lineal respecto a la entrada original x. Si ϕ contiene cuadrados y productos cruzados, el modelo resultante puede describir relaciones cuadráticas en las variables originales.

1.1. Mínimos cuadrados

El método de mínimos cuadrados selecciona el vector w que minimiza la suma de los errores de predicción al cuadrado:

$$\widehat{w}_{\text{LS}} = \arg\min_{w \in \mathbb{R}^Q} J(w), \qquad J(w) = \|t - \Phi w\|_2^2 . \tag{1}$$

La norma al cuadrado se puede desarrollar como

$$J(w) = (t - \Phi w)^\top (t - \Phi w) = t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w.$$

Derivando respecto al vector w:

$$\nabla_w J(w) = -2\Phi^\top t + 2\Phi^\top \Phi w.$$

En un mínimo diferenciable, el gradiente debe ser cero. Por tanto,

$$-2\Phi^\top t + 2\Phi^\top \Phi \widehat{w} = 0 \quad \Longrightarrow \quad \boxed{\Phi^\top \Phi \widehat{w} = \Phi^\top t.}$$

Estas son las **ecuaciones normales**. Si $\Phi^\top \Phi$ es invertible, se multiplica por su inversa y se obtiene

$$\boxed{\widehat{w}_{\text{LS}} = (\Phi^\top \Phi)^{-1} \Phi^\top t.} \tag{2}$$

Concepto clave

Condiciones de existencia y unicidad.

- Un minimizador de mínimos cuadrados existe para cualquier matriz real Φ finita; el problema consiste en proyectar t sobre el espacio columna de Φ.
- El minimizador es único si y solo si las columnas de Φ son linealmente independientes, es decir, $\text{rank}(\Phi) = Q$. Equivalentemente, $\Phi^\top \Phi$ es definida positiva e invertible.
- Si las columnas no son independientes, puede haber varios vectores w con la misma predicción Φw. Una solución de norma mínima es $\widehat{w} = \Phi^\dagger t$, donde $\Phi^\dagger$ es la pseudoinversa de Moore–Penrose.

Las dimensiones concuerdan: $\Phi^\top \Phi$ es $Q \times Q$, $\Phi^\top t$ es $Q \times 1$ y $\widehat{w}$ es $Q \times 1$.

1.2. Mínimos cuadrados regularizados

Se incorpora una penalización cuadrática que desfavorece coeficientes de gran magnitud:

$$\widehat{w}_\lambda = \arg\min_w \left\{ \|t - \Phi w\|_2^2 + \lambda \|w\|_2^2 \right\}, \qquad \lambda > 0. \tag{3}$$

Como $\|w\|_2^2 = w^\top w$, el objetivo se escribe

$$J_\lambda(w) = t^\top t - 2w^\top \Phi^\top t + w^\top \Phi^\top \Phi w + \lambda w^\top w.$$

Su gradiente es

$$\nabla_w J_\lambda(w) = -2\Phi^\top t + 2\Phi^\top \Phi w + 2\lambda w.$$

Igualando a cero:

$$(\Phi^\top \Phi + \lambda I_Q)\widehat{w}_\lambda = \Phi^\top t.$$

Luego,

$$\boxed{\widehat{w}_\lambda = (\Phi^\top \Phi + \lambda I_Q)^{-1} \Phi^\top t.} \tag{4}$$

La matriz es invertible porque, para todo $v \neq 0$,

$$v^\top (\Phi^\top \Phi + \lambda I_Q) v = \|\Phi v\|_2^2 + \lambda \|v\|_2^2 > 0.$$

Así, con $\lambda > 0$ la solución es única aunque Φ no tenga rango columna completo.

Intuición

La penalización $\lambda \|w\|^2$ no obliga a que w sea cero; aumenta el costo de soluciones con coeficientes grandes. En general, al aumentar λ, los coeficientes se contraen hacia cero. Esto puede reducir la variabilidad y evitar sobreajuste, a cambio de introducir sesgo. Si λ es demasiado grande, el modelo puede quedar demasiado restringido.

Atención

La fórmula anterior corresponde a la convención exacta del enunciado: error cuadrático sin factor $1/N$ más $\lambda \|w\|^2$. Si se usa $\frac{1}{N} \|t - \Phi w\|^2 + \lambda \|w\|^2$, la escala efectiva de λ cambia. Es importante mantener la misma convención al relacionar regularización y MAP.

1.3. Máxima verosimilitud

Supóngase ruido i.i.d. gaussiano:

$$\eta_n \sim \mathcal{N}(0, \sigma_\eta^2), \qquad t_n \mid x_n, w \sim \mathcal{N}(\phi(x_n)^\top w, \sigma_\eta^2).$$

La densidad condicional de cada respuesta es

$$p(t_n \mid x_n, w) = \frac{1}{\sqrt{2\pi\sigma_\eta^2}} \exp\left[-\frac{(t_n - \phi(x_n)^\top w)^2}{2\sigma_\eta^2} \right].$$

Por independencia condicional de las observaciones, la verosimilitud conjunta es el producto:

$$\begin{aligned} L(w) = p(t \mid \Phi, w) &= \prod_{n=1}^{N} p(t_n \mid x_n, w) \\ &= (2\pi\sigma_\eta^2)^{-N/2} \exp\left[-\frac{1}{2\sigma_\eta^2} \sum_{n=1}^{N} (t_n - \phi(x_n)^\top w)^2 \right] \\ &= (2\pi\sigma_\eta^2)^{-N/2} \exp\left[-\frac{\|t - \Phi w\|_2^2}{2\sigma_\eta^2} \right]. \end{aligned}$$

Maximizar $L(w)$ es equivalente a maximizar su logaritmo, ya que log es estrictamente creciente:

$$\ell(w) = \log L(w) = -\frac{N}{2} \log(2\pi\sigma_\eta^2) - \frac{1}{2\sigma_\eta^2} \|t - \Phi w\|_2^2 .$$

El primer término no depende de w. Por eso,

$$\widehat{w}_{\mathrm{ML}} = \arg\max_w \ell(w) = \arg\min_w \|t - \Phi w\|_2^2 .$$

Se concluye que

Resultado importante

$$\boxed{\widehat{w}_{\mathrm{ML}} = \widehat{w}_{\mathrm{LS}}.}$$

Con ruido gaussiano i.i.d. de media cero y varianza conocida, el estimador de máxima verosimilitud para w coincide con mínimos cuadrados. La varianza afecta la escala de la log-verosimilitud, pero no el minimizador.

1.4. Máximo a posteriori (MAP)

Ahora se asigna al vector de parámetros el prior gaussiano

$$w \sim \mathcal{N}(0, \sigma_w^2 I_Q), \qquad p(w) \propto \exp\left(-\frac{1}{2\sigma_w^2}\,\|w\|_2^2\right).$$

Por la regla de Bayes,

$$p(w \mid t, \Phi) = \frac{p(t \mid \Phi, w)p(w)}{p(t \mid \Phi)}.$$

Para maximizar respecto a w, el denominador $p(t \mid \Phi)$ es constante. Entonces

$$\widehat{w}_{\mathrm{MAP}} = \arg\max_w p(t \mid \Phi, w)p(w) = \arg\max_w \left\{\log p(t \mid \Phi, w) + \log p(w)\right\}.$$

Al conservar solo los términos que dependen de w y cambiar de maximización a minimización, resulta

$$\widehat{w}_{\mathrm{MAP}} = \arg\min_w \left\{\frac{1}{2\sigma_\eta^2}\,\|t - \Phi w\|_2^2 + \frac{1}{2\sigma_w^2}\,\|w\|_2^2\right\}.$$

Multiplicando el objetivo por la constante positiva $2\sigma_\eta^2$ no se altera su minimizador:

$$\widehat{w}_{\mathrm{MAP}} = \arg\min_w \left\{\|t - \Phi w\|_2^2 + \frac{\sigma_\eta^2}{\sigma_w^2}\,\|w\|_2^2\right\}.$$

Comparando con el objetivo de mínimos cuadrados regularizados, queda

$$\boxed{\lambda = \frac{\sigma_\eta^2}{\sigma_w^2}}, \qquad \boxed{\sigma_w^2 = \frac{\sigma_\eta^2}{\lambda}}. \tag{5}$$

La solución cerrada es

$$\boxed{\widehat{w}_{\mathrm{MAP}} = \left(\Phi^\top \Phi + \frac{\sigma_\eta^2}{\sigma_w^2} I_Q\right)^{-1} \Phi^\top t.} \tag{6}$$

Intuición

MAP combina dos fuentes de información: los datos favorecen parámetros con buen ajuste, mientras que el prior favorece parámetros próximos a cero. Un prior más concentrado (menor σ_w^2) penaliza más los coeficientes, equivalente a aumentar λ. Un ruido más grande (mayor σ_η^2), bajo esta convención, reduce la confianza en los datos frente al prior y también aumenta λ si el prior se mantiene fijo.

1.5. Implementación y análisis en Python

Se usan $N = 300$, $P = 5$, $Q = 20$ y semilla fija 42. La transformación contiene, en este orden: las cinco columnas originales $x_1, \ldots, x_5$; sus cuadrados $x_1^2, \ldots, x_5^2$; y los diez productos $x_i x_j$ para $i < j$, enumerados lexicográficamente: $(1,2), (1,3), (1,4), (1,5), (2,3), (2,4), (2,5), (3,4), (3,5), (4,5)$.

```python
import numpy as np

SEED = 42
rng = np.random.default_rng(SEED)
N, P, Q = 300, 5, 20
sigma_eta = 0.5
lam = 1.0

# X tiene filas i.i.d. N(0, I_P).
X = rng.normal(0.0, 1.0, size=(N, P))

# Phi: originales, cuadrados y productos cruzados i < j.
features = [X, X**2]
for i in range(P):
    for j in range(i + 1, P):
        features.append((X[:, i] * X[:, j])[:, None])
Phi = np.concatenate(features, axis=1)
assert Phi.shape == (N, Q)

w_star = rng.normal(0.0, 1.0, size=Q)
eta = rng.normal(0.0, sigma_eta, size=N)
t = Phi @ w_star + eta

# Division aleatoria 80/20; el ajuste usa solo entrenamiento.
indices = rng.permutation(N)
idx_train, idx_test = indices[:240], indices[240:]
A, b = Phi[idx_train], t[idx_train]
A_test, b_test = Phi[idx_test], t[idx_test]

# Minimos cuadrados y maxima verosimilitud.
w_ls = np.linalg.lstsq(A, b, rcond=None)[0]
w_ml = w_ls.copy() # coincide con LS en este modelo gaussiano

# Ridge: SSE + lambda * ||w||^2.
w_ridge = np.linalg.solve(A.T @ A + lam*np.eye(Q), A.T @ b)

# Prior compatible: sigma_w^2 = sigma_eta^2 / lambda.
sigma_w2 = sigma_eta**2 / lam
w_map = np.linalg.solve(
    A.T @ A + (sigma_eta**2/sigma_w2)*np.eye(Q), A.T @ b
)

models = {
    "Minimos cuadrados": w_ls,
    "Maxima verosimilitud": w_ml,
    "Regularizado (ridge)": w_ridge,
    "MAP": w_map,
}
for name, w in models.items():
    mse_train = np.mean((A @ w - b)**2)
    mse_test = np.mean((A_test @ w - b_test)**2)
    err_w = np.linalg.norm(w - w_star)
    print(f"{name:24s} MSE train={mse_train:.6f} "
          f"MSE test={mse_test:.6f} ||w-w*||={err_w:.6f}")
```

Listing 1: Generacion de datos y ajuste de los cuatro enfoques

Resultados de una ejecución con la semilla indicada. Para LS y ML se obtiene el mismo vector, salvo precisión numérica. Ridge y MAP también coinciden cuando se usa $\sigma_w^2 = \sigma_\eta^2/\lambda = 0.25$.

Método	MSE entrenamiento	MSE prueba	$\|\widehat{w} - w^\star\|_2$
Mínimos cuadrados	0.238900	0.285008	0.120489
Máxima verosimilitud	0.238900	0.285008	0.120489
Regularizado (ridge), $\lambda = 1$	0.239233	0.279331	0.125542
MAP, $\sigma_w^2 = 0.25$	0.239233	0.279331	0.125542

Atención

Los valores numéricos dependen de la semilla, de la secuencia exacta de llamadas al generador y del orden de la división. Se deben comparar con los resultados producidos por el bloque de código completo, no con resultados de una implementación que use otra secuencia aleatoria.

Análisis. LS y ML coinciden porque ambos minimizan el mismo error cuadrático. Ridge y MAP coinciden porque el prior gaussiano produce una penalización cuadrática con $\lambda = \sigma_\eta^2/\sigma_w^2$. La regularización aumenta ligeramente el error de entrenamiento, pero en esta ejecución reduce el error de prueba. Eso ilustra el compromiso entre ajuste y generalización. El error $\|\widehat{w} - w^\star\|$ puede aumentar un poco con regularización porque esta introduce sesgo, aun cuando mejore la predicción de prueba.

Parte II

Espacios RKHS, embeddings de media y MMD

2. Conceptos previos: kernel, mapa de características y RKHS

Un kernel simétrico definido positivo es una función

$$k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$$

tal que $k(x, y) = k(y, x)$ y, para cualquier elección de puntos $x_1, \ldots, x_r$ y coeficientes $a_1, \ldots, a_r \in \mathbb{R}$,

$$\sum_{i=1}^{r} \sum_{j=1}^{r} a_i a_j k(x_i, x_j) \geq 0.$$

A todo kernel de este tipo se le asocia un RKHS $\mathcal{H}_k$ en el que las funciones $k(x, \cdot)$ pertenecen al espacio y se cumple la propiedad reproductora.

Concepto clave

¿Qué significa $k(x, \cdot)$? El punto x queda fijo y el punto indicado por $\cdot$ es el argumento libre de una función. Por tanto, $k(x, \cdot)$ es una función en el RKHS, no el producto de $k(x)$ por algo. El mapa de características inducido por el kernel se puede escribir como $\phi_k(x) = k(x, \cdot) \in \mathcal{H}_k$.

Atención

¿Una variable aleatoria puede ser una matriz? Sí. Formalmente, una variable aleatoria es una aplicación medible desde un espacio de probabilidad hacia un espacio de valores; dichos valores pueden ser escalares, vectores, matrices u objetos más generales. En 2.1, el enunciado no especifica una forma particular de X: basta que X tome valores en $\mathcal{X}$ y que la expectativa funcional esté bien definida.

2.1. Definición rigurosa del embedding de media

Sea X una variable aleatoria con distribución P_X sobre $\mathcal{X}$ y sea k un kernel con RKHS $\mathcal{H}_k$. El embedding de media de P_X es la esperanza, en el sentido de una variable aleatoria con valores en un espacio de Hilbert, de la función $k(X, \cdot)$:

$$\boxed{\mu_k(P_X) = \mathbb{E}_{X\sim P_X}[k(X,\cdot)] = \int_{\mathcal{X}} k(x,\cdot)\, dP_X(x).} \tag{7}$$

Para que la esperanza de Hilbert (integral de Bochner) exista, una condición suficiente habitual es

$$\mathbb{E}[k(X,X)] < \infty.$$

En efecto, en un RKHS,

$$\|k(x,\cdot)\|^2_{\mathcal{H}_k} = \langle k(x,\cdot), k(x,\cdot)\rangle_{\mathcal{H}_k} = k(x,x),$$

y así, mediante Cauchy–Schwarz,

$$\mathbb{E}\,\|k(X,\cdot)\|_{\mathcal{H}_k} = \mathbb{E}\sqrt{k(X,X)} \le \sqrt{\mathbb{E}[k(X,X)]} < \infty.$$

Esta integrabilidad permite definir la esperanza como un elemento del espacio funcional.

2.2. Por qué $\mu_k \in \mathcal{H}_k$ y su interpretación geométrica

Por definición, $k(x,\cdot) \in \mathcal{H}_k$ para cada $x \in \mathcal{X}$. Si la esperanza de estas funciones existe como integral de Bochner, dicha esperanza también es un elemento del espacio de Hilbert. Luego

$$\boxed{\mu_k \in \mathcal{H}_k.}$$

La propiedad reproductora establece que, para toda función $f \in \mathcal{H}_k$,

$$f(x) = \langle f, k(x,\cdot)\rangle_{\mathcal{H}_k}. \tag{8}$$

Aplicando la propiedad y la linealidad de la esperanza,

$$\begin{aligned}\langle f, \mu_k\rangle_{\mathcal{H}_k} &= \langle f, \mathbb{E}[k(X,\cdot)]\rangle_{\mathcal{H}_k} \\ &= \mathbb{E}\left[\langle f, k(X,\cdot)\rangle_{\mathcal{H}_k}\right] \\ &= \mathbb{E}[f(X)].\end{aligned}$$

Así, el embedding codifica las esperanzas de todas las funciones admisibles del RKHS mediante productos internos.

Resultado importante

$$\boxed{\mathbb{E}[f(X)] = \langle f, \mu_k\rangle_{\mathcal{H}_k} \quad \text{para todo } f \in \mathcal{H}_k.}$$

Intuición

Geométricamente, μ_k es el *centroide* o promedio de los puntos $k(x,\cdot)$ en el espacio de características funcional. No es, en general, el promedio aritmético de los vectores originales x. Cada observación se representa como una función del RKHS y el embedding promedia esas funciones. Si el kernel es

característico, distribuciones distintas tienen embeddings distintos; sin esa propiedad, el embedding no necesariamente identifica de forma única la distribución.

2.3. Discrepancia máxima de medias (MMD)

Sean $X \sim P_X$ y $Y \sim P_Y$, con embeddings

$$\mu_X = \mathbb{E}[k(X, \cdot)], \qquad \mu_Y = \mathbb{E}[k(Y, \cdot)].$$

La MMD poblacional cuadrática se define como

$$\mathrm{MMD}^2(P_X, P_Y) = \|\mu_X - \mu_Y\|^2_{\mathcal{H}_k}.$$

Paso 1: desarrollar la norma cuadrática

Por la identidad $\|a - b\|^2 = \langle a, a\rangle + \langle b, b\rangle - 2\langle a, b\rangle$,

$$\mathrm{MMD}^2(P_X, P_Y) = \langle \mu_X, \mu_X\rangle_{\mathcal{H}_k} + \langle \mu_Y, \mu_Y\rangle_{\mathcal{H}_k} - 2\langle \mu_X, \mu_Y\rangle_{\mathcal{H}_k}. \tag{9}$$

Sean X' y Y' copias independientes de X y Y, respectivamente. Al sustituir las esperanzas y aplicar la linealidad,

$$\langle \mu_X, \mu_X\rangle_{\mathcal{H}_k} = \mathbb{E}_{X,X'}\left[\langle k(X, \cdot), k(X', \cdot)\rangle_{\mathcal{H}_k}\right].$$

Por la propiedad reproductora del kernel,

$$\langle k(x, \cdot), k(x', \cdot)\rangle_{\mathcal{H}_k} = k(x, x'),$$

por lo que

$$\langle \mu_X, \mu_X\rangle = \mathbb{E}_{X,X'}[k(X, X')].$$

De manera análoga,

$$\langle \mu_Y, \mu_Y\rangle = \mathbb{E}_{Y,Y'}[k(Y, Y')], \qquad \langle \mu_X, \mu_Y\rangle = \mathbb{E}_{X,Y}[k(X, Y)].$$

Sustituyendo en (9):

$$\boxed{\mathrm{MMD}^2(P_X, P_Y) = \mathbb{E}[k(X, X')] + \mathbb{E}[k(Y, Y')] - 2\mathbb{E}[k(X, Y)].} \tag{10}$$

Esta es la forma poblacional: contiene expectativas respecto de las distribuciones, no sumas sobre las muestras observadas.

Paso 2: sustituir las distribuciones por muestras

Sean $x_1, \ldots, x_n$ una muestra de P_X y $y_1, \ldots, y_m$ una muestra de P_Y. Sus embeddings empíricos son

$$\widehat{\mu}_X = \frac{1}{n}\sum_{i=1}^{n} k(x_i, \cdot), \qquad \widehat{\mu}_Y = \frac{1}{m}\sum_{j=1}^{m} k(y_j, \cdot).$$

La MMD empírica sesgada se define como la distancia cuadrática entre estos embeddings empíricos:

$$\widehat{\mathrm{MMD}}_b^{\,2} = \|\widehat{\mu}_X - \widehat{\mu}_Y\|^2_{\mathcal{H}_k}.$$

Desarrollamos cada término:

$$\begin{aligned}\|\widehat{\mu}_X\|^2_{\mathcal{H}_k} &= \left\langle \frac{1}{n}\sum_i k(x_i,\cdot), \frac{1}{n}\sum_j k(x_j,\cdot) \right\rangle \\ &= \frac{1}{n^2}\sum_{i=1}^n\sum_{j=1}^n \langle k(x_i,\cdot), k(x_j,\cdot)\rangle_{\mathcal{H}_k} \\ &= \frac{1}{n^2}\sum_{i=1}^n\sum_{j=1}^n k(x_i,x_j).\end{aligned}$$

Igualmente,

$$\|\widehat{\mu}_Y\|^2_{\mathcal{H}_k} = \frac{1}{m^2}\sum_{i=1}^m\sum_{j=1}^m k(y_i,y_j),$$

y

$$\langle \widehat{\mu}_X, \widehat{\mu}_Y\rangle_{\mathcal{H}_k} = \frac{1}{nm}\sum_{i=1}^n\sum_{j=1}^m k(x_i,y_j).$$

Por tanto,

$$\boxed{\begin{aligned}\widehat{\mathrm{MMD}}_b^{\,2} = &\frac{1}{n^2}\sum_{i,j=1}^n k(x_i,x_j) + \frac{1}{m^2}\sum_{i,j=1}^m k(y_i,y_j) \\ &- \frac{2}{nm}\sum_{i=1}^n\sum_{j=1}^m k(x_i,y_j).\end{aligned}} \tag{11}$$

Paso 3: escribir la expresión en forma matricial

Se definen las matrices de Gram:

$$K_{XX}[i,j] = k(x_i,x_j), \quad K_{YY}[i,j] = k(y_i,y_j), \quad K_{XY}[i,j] = k(x_i,y_j).$$

Sus dimensiones son

$$K_{XX} \in \mathbb{R}^{n\times n}, \qquad K_{YY} \in \mathbb{R}^{m\times m}, \qquad K_{XY} \in \mathbb{R}^{n\times m}.$$

Como $\mathbf{1}_n^\top K_{XX}\mathbf{1}_n$ suma todos los elementos de K_{XX}, y análogamente para los otros términos, (11) equivale a

$$\boxed{\widehat{\mathrm{MMD}}_b^{\,2} = \frac{1}{n^2}\mathbf{1}_n^\top K_{XX}\mathbf{1}_n + \frac{1}{m^2}\mathbf{1}_m^\top K_{YY}\mathbf{1}_m - \frac{2}{nm}\mathbf{1}_n^\top K_{XY}\mathbf{1}_m.} \tag{12}$$

Las dimensiones de cada producto son:

$$(1\times n)(n\times n)(n\times 1) \to 1\times 1,$$

$$(1\times m)(m\times m)(m\times 1) \to 1\times 1,$$

$$(1\times n)(n\times m)(m\times 1) \to 1\times 1.$$

Los tres términos son escalares, de modo que su suma está bien definida.

Atención

¿Por qué se llama sesgado? En los términos internos se incluyen los elementos diagonales $k(x_i, x_i)$ y $k(y_j, y_j)$. Por ello, el estimador no es, en general, insesgado para la MMD poblacional. En cambio, coincide exactamente con la distancia cuadrática entre los dos embeddings empíricos y, por esa razón, es no negativo en aritmética exacta. Una versión insesgada sustituye los términos internos por sumas sin diagonal, con denominadores $n(n-1)$ y $m(m-1)$; esa versión no es necesariamente no negativa en cada muestra.

2.4. Implementación con MNIST y Fashion-MNIST

¿Qué se compara?

El propósito no es entrenar un clasificador, sino comparar dos distribuciones de imágenes. Cada imagen de 28×28 se convierte en un vector de 784 componentes y se normaliza a $[0, 1]$. Se seleccionan 1000 imágenes de cada conjunto y se separan en dos grupos disjuntos de 500. Se comparan: (i) MNIST frente a Fashion-MNIST, (ii) los dos grupos de MNIST y (iii) los dos grupos de Fashion-MNIST. Las etiquetas de clase no intervienen.

El kernel gaussiano es

$$k(u, v) = \exp\left(-\frac{\|u - v\|_2^2}{2\sigma^2}\right).$$

Se usa un mismo σ en todas las comparaciones. En el procedimiento de la ejecución reportada, σ es la mediana de las distancias euclídeas entre pares de las 1000 imágenes reunidas en la comparación principal.

```python
import torch
import pandas as pd
from torchvision.datasets import MNIST, FashionMNIST

SEED = 2026
torch.manual_seed(SEED)
torch.set_num_threads(2)
DATA_DIR = "./data"

# download=True descarga los archivos del dataset si no existen localmente.
mnist = MNIST(root=DATA_DIR, train=True, download=True)
fashion = FashionMNIST(root=DATA_DIR, train=True, download=True)

def seleccionar_dividir(dataset, seed):
    g = torch.Generator().manual_seed(seed)
    indices = torch.randperm(len(dataset.data), generator=g)[:1000]
    imagenes = dataset.data[indices].reshape(1000, 784).float() / 255.0
    return imagenes[:500], imagenes[500:]

X_m1, X_m2 = seleccionar_dividir(mnist, SEED)
Y_f1, Y_f2 = seleccionar_dividir(fashion, SEED + 1)

# Sigma: mediana de distancias entre las 1000 imagenes principales.
combinadas = torch.cat([X_m1, Y_f1], dim=0)
sigma = torch.median(torch.pdist(combinadas, p=2)).item()
print(f"sigma = {sigma:.6f}")

def rbf(A, B, sigma):
    d2 = torch.cdist(A, B, p=2).square()
    return torch.exp(-d2 / (2.0 * sigma**2))

def mmd2_sesgada(A, B, sigma):
    n, m = A.shape[0], B.shape[0]
```

```
    K_XX = rbf(A, A, sigma)
    K_YY = rbf(B, B, sigma)
    K_XY = rbf(A, B, sigma)
    value = (K_XX.sum() / n**2 + K_YY.sum() / m**2
             - 2.0 * K_XY.sum() / (n*m))
    return value.item(), K_XX, K_YY, K_XY

comparaciones = [
    ("MNIST vs. Fashion-MNIST", X_m1, Y_f1),
    ("MNIST: grupo 1 vs. grupo 2", X_m1, X_m2),
    ("Fashion-MNIST: grupo 1 vs. grupo 2", Y_f1, Y_f2),
]
resultados = []
for nombre, A, B in comparaciones:
    valor, K_XX, K_YY, K_XY = mmd2_sesgada(A, B, sigma)
    resultados.append({"Comparacion": nombre, "n": len(A),
                       "m": len(B), "MMD2 sesgada": valor})
    print(nombre, K_XX.shape, K_YY.shape, K_XY.shape)

print(pd.DataFrame(resultados).round(6))
```

Listing 2: Codigo completo de referencia para el punto 2.4 (PyTorch)

Dimensiones y resultados

Para cada comparación, $n = m = 500$. Por tanto,

$$K_{XX}, K_{YY}, K_{XY} \in \mathbb{R}^{500\times 500}.$$

La ejecución que se está analizando produjo $\sigma = 11.120461$ y los siguientes valores reportados:

Comparación	n	m	$\widehat{\mathrm{MMD}}_b^2$
MNIST vs. Fashion-MNIST	500	500	0.116298
MNIST: grupo 1 vs. grupo 2	500	500	0.001304
Fashion-MNIST: grupo 1 vs. grupo 2	500	500	0.001631

Resultado importante

La MMD^2 entre MNIST y Fashion-MNIST es mucho mayor que las dos MMD^2 de referencia dentro de cada conjunto. En esta ejecución, el valor principal es aproximadamente 89.2 veces el de la partición de MNIST y 71.3 veces el de Fashion-MNIST. Esto es coherente con diferencias entre los tipos de imágenes de los dos conjuntos.

Interpretación y limitaciones

- **Ancho de banda.** Si σ es muy pequeño, el kernel entre imágenes diferentes tiende a cero y la comparación puede quedar dominada por similitudes casi nulas. Si σ es muy grande, muchas similitudes se aproximan a uno y las diferencias se comprimen. La mediana ofrece una escala basada en las distancias observadas, pero no es una elección universalmente óptima.
- **Variabilidad muestral.** Dos grupos distintos del mismo conjunto no tienen por qué producir $\mathrm{MMD}^2 = 0$: son muestras finitas diferentes y sus embeddings empíricos fluctúan.
- **Sin etiquetas.** La comparación se basa exclusivamente en imágenes y kernel; las etiquetas de clase no se utilizan.

- **No es una prueba de hipótesis.** Un valor MMD^2 grande respecto a dos referencias sugiere una diferencia descriptiva, pero por sí solo no prueba significancia estadística. Para afirmar formalmente que las distribuciones difieren, se debe fijar un nivel de significancia y aplicar, por ejemplo, una prueba de permutación.

Atención

La cifra $\sigma = 11.120461$ y los tres valores de MMD^2 se reproducen como resultados de la ejecución presentada. Para obtener exactamente los mismos números, deben mantenerse la misma semilla, la misma selección de imágenes, la misma definición de distancia mediana y el mismo procesamiento de los datos. El código calcula las distancias sobre las imágenes normalizadas y utiliza σ fijo en las tres comparaciones.

Parte III

Correlación de Pearson

3. Correlación de Pearson: espacio original y RKHS

3.1. Coeficiente de Pearson en el espacio original

Sean $x, y \in \mathbb{R}^{N\times 1}$ vectores de N observaciones emparejadas. La media muestral de x es

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i = \frac{1}{N}\mathbf{1}_N^\top x,$$

y la de y es $\bar{y} = \frac{1}{N}\mathbf{1}_N^\top y$. La correlación muestral de Pearson es

$$\widehat{\rho}_{XY} = \frac{\sum_{i=1}^{N}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\left[\sum_{i=1}^{N}(x_i-\bar{x})^2\right]\left[\sum_{i=1}^{N}(y_i-\bar{y})^2\right]}}. \tag{13}$$

Paso 1: construir la matriz de centrado

Definimos

$$\boxed{H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top.} \tag{14}$$

Su efecto sobre x es

$$\begin{aligned} Hx &= \left(I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top\right)x \\ &= x - \frac{1}{N}\mathbf{1}_N(\mathbf{1}_N^\top x) \\ &= x - \bar{x}\mathbf{1}_N \\ &= \begin{bmatrix} x_1-\bar{x} & \cdots & x_N-\bar{x}\end{bmatrix}^\top. \end{aligned}$$

Por tanto, Hx es el vector original centrado. De la misma manera, $Hy = y - \bar{y}\mathbf{1}_N$.

La matriz H tiene tres propiedades útiles:

$$H^\top = H \quad \text{(simétrica)}, \qquad H^2 = H \quad \text{(idempotente)}, \qquad H\mathbf{1}_N = 0.$$

La identidad $H^2 = H$ implica que centrar dos veces no modifica el resultado que se obtiene al centrar una vez.

Paso 2: convertir las sumas en productos matriciales

El numerador de (13) es la suma de productos componente a componente de los vectores centrados:

$$\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y}) = (Hx)^\top(Hy).$$

Al expandir el producto y usar $H^\top H = H^2 = H$,

$$(Hx)^\top(Hy) = x^\top H^\top Hy = x^\top Hy.$$

Análogamente,

$$\sum_i (x_i - \bar{x})^2 = (Hx)^\top(Hx) = x^\top Hx,$$

$$\sum_i (y_i - \bar{y})^2 = (Hy)^\top(Hy) = y^\top Hy.$$

Sustituyendo en el coeficiente:

$$\boxed{\widehat{\rho}_{XY} = \frac{x^\top Hy}{\sqrt{(x^\top Hx)(y^\top Hy)}}.} \tag{15}$$

Concepto clave

¿Por qué aparece H en varias partes? Es la misma matriz de centrado que se reutiliza para centrar x y y. En $x^\top Hy$ centra las observaciones antes de calcular la covariación; en $x^\top Hx$ y $y^\top Hy$ calcula las sumas de cuadrados centradas. No se están definiendo matrices H distintas. Las dimensiones también son compatibles: $x^\top Hy$ es $(1 \times N)(N \times N)(N \times 1)$, por lo que el resultado es un escalar.

La fórmula requiere que ambas varianzas muestrales sean positivas; equivalentemente, x y y no pueden ser vectores constantes.

3.2. Alineamiento centrado de kernels en RKHS

Sean N observaciones emparejadas para dos conjuntos de variables, y sean $K_X, K_Y \in \mathbb{R}^{N\times N}$ sus matrices de Gram. Se define la versión centrada de cada matriz como

$$K_{X,c} = HK_XH, \qquad K_{Y,c} = HK_YH,$$

donde $H = I_N - \frac{1}{N}\mathbf{1}_N\mathbf{1}_N^\top$ es la misma matriz de centrado de (14).

¿Por qué se escribe HKH y aparece H dos veces?

La multiplicación por H a la izquierda centra las filas y la multiplicación por H a la derecha centra las columnas (según la convención de indexación de la matriz de Gram). En una matriz de Gram simétrica, filas y columnas representan las mismas observaciones en los dos argumentos del kernel. Por tanto, se centra en ambas direcciones para eliminar la media. Los dos factores son la misma matriz H, no dos matrices diferentes.

Paso 1: producto interno de Frobenius normalizado

El producto interno de Frobenius entre matrices es

$$\langle A, B\rangle_F = \operatorname{tr}(A^\top B), \qquad \|A\|_F = \sqrt{\operatorname{tr}(A^\top A)}.$$

El alineamiento centrado se define como

$$\rho_{\mathrm{RKHS}}(K_X, K_Y) = \frac{\langle K_{X,c}, K_{Y,c}\rangle_F}{\|K_{X,c}\|_F \, \|K_{Y,c}\|_F}, \tag{16}$$

suponiendo que los denominadores sean distintos de cero.

Paso 2: desarrollar el numerador hasta una traza

Como H, K_X y K_Y son simétricas, $K_{X,c}^\top = HK_XH$. Entonces

$$\begin{aligned}\langle K_{X,c}, K_{Y,c}\rangle_F &= \operatorname{tr}(K_{X,c}^\top K_{Y,c}) \\ &= \operatorname{tr}\left((HK_XH)(HK_YH)\right) \\ &= \operatorname{tr}(HK_XH^2K_YH) \\ &= \operatorname{tr}(HK_XHK_YH),\end{aligned}$$

donde usamos $H^2 = H$. Por la propiedad cíclica de la traza, $\operatorname{tr}(ABCD) = \operatorname{tr}(BCDA)$ cuando las dimensiones permiten los productos:

$$\operatorname{tr}(HK_XHK_YH) = \operatorname{tr}(K_XHK_YH^2) = \operatorname{tr}(K_XHK_YH).$$

Por tanto,

$$\boxed{\langle K_{X,c}, K_{Y,c}\rangle_F = \operatorname{tr}(K_XHK_YH).} \tag{17}$$

Paso 3: desarrollar los denominadores

Para K_X,

$$\begin{aligned}\|K_{X,c}\|_F^2 &= \operatorname{tr}(K_{X,c}^\top K_{X,c}) \\ &= \operatorname{tr}(HK_XH\,HK_XH) \\ &= \operatorname{tr}(HK_XHK_XH) \\ &= \operatorname{tr}(K_XHK_XH),\end{aligned}$$

donde, de nuevo, se usaron $H^2 = H$ y la propiedad cíclica de la traza. Similarmente,

$$\|K_{Y,c}\|_F^2 = \operatorname{tr}(K_Y H K_Y H).$$

Al insertar las expresiones en (16), obtenemos

$$\boxed{\rho_{\mathrm{RKHS}}(K_X, K_Y) = \frac{\operatorname{tr}(K_X H K_Y H)}{\sqrt{\operatorname{tr}(K_X H K_X H)\ \operatorname{tr}(K_Y H K_Y H)}}.} \tag{18}$$

Cada K y H es $N \times N$; todos los productos dentro de las trazas son $N \times N$ y cada traza es un escalar.

Atención

Aunque el enunciado lo llama índice de correlación en RKHS, la cantidad de (18) es específicamente un **alineamiento centrado de kernels** (centered kernel alignment). No es, en general, el coeficiente de Pearson clásico calculado sobre las observaciones originales.

Caso especial: kernels lineales y $P = Q = 1$

Si las observaciones de ambas variables son escalares, $x, y \in \mathbb{R}^N$, y se usan kernels lineales,

$$K_X = xx^\top, \qquad K_Y = yy^\top.$$

Al centrar,

$$K_{X,c} = Hxx^\top H = (Hx)(Hx)^\top, \qquad K_{Y,c} = (Hy)(Hy)^\top.$$

Definamos $u = Hx$ y $v = Hy$. Entonces $K_{X,c} = uu^\top$ y $K_{Y,c} = vv^\top$.

El numerador del alineamiento centrado es

$$\begin{aligned}\left\langle uu^\top, vv^\top \right\rangle_F &= \operatorname{tr}\left((uu^\top)^\top vv^\top\right) \\ &= \operatorname{tr}(uu^\top vv^\top) \\ &= \operatorname{tr}\left(u(u^\top v)v^\top\right) \\ &= (u^\top v)^2.\end{aligned}$$

Para la norma de Frobenius,

$$\left\|uu^\top\right\|_F^2 = \operatorname{tr}(uu^\top uu^\top) = (u^\top u)^2,$$

de modo que $\left\|uu^\top\right\|_F = u^\top u = \|u\|_2^2$. Similarmente, $\left\|vv^\top\right\|_F = v^\top v$. Por consiguiente,

$$\rho_{\mathrm{RKHS}}(K_X, K_Y) = \frac{(u^\top v)^2}{(u^\top u)(v^\top v)}.$$

Pero el coeficiente de Pearson del punto 3.1 es

$$\widehat{\rho}_{XY} = \frac{x^\top H y}{\sqrt{(x^\top H x)(y^\top H y)}} = \frac{u^\top v}{\sqrt{(u^\top u)(v^\top v)}}.$$

Al elevar al cuadrado,

$$\boxed{\rho_{\mathrm{RKHS}}(K_X, K_Y) = \widehat{\rho}_{XY}^2.} \tag{19}$$

Resultado importante

En el caso escalar y lineal, el alineamiento centrado de kernels coincide con el cuadrado de Pearson, no con Pearson con signo. Como el resultado contiene $(u^\top v)^2$, una correlación positiva y una negativa de igual magnitud producen el mismo alineamiento. Por ejemplo, $\widehat{\rho} = 0.8$ y $\widehat{\rho} = -0.8$ dan ambos $\rho_{\text{RKHS}} = 0.64$.

Resumen de resultados y errores conceptuales que conviene evitar

Tema	Idea central
Mínimos cuadrados	Minimiza $\|t - \Phi w\|^2$. La inversa normal requiere rango columna completo; en caso contrario puede usarse la pseudoinversa.
Regularización	Añade $\lambda \|w\|^2$ y da $(\Phi^\top \Phi + \lambda I)^{-1} \Phi^\top t$. $\lambda > 0$ hace la matriz definida positiva.
Máxima verosimilitud	Con ruido gaussiano i.i.d. de media cero, maximizar la verosimilitud equivale a minimizar la suma de cuadrados; ML y LS coinciden.
MAP	Con prior gaussiano isotrópico, MAP equivale a ridge con $\lambda = \sigma_\eta^2 / \sigma_w^2$ para la convención de objetivo usada aquí.
Embedding de media	$\mu_k = \mathbb{E}[k(X, \cdot)] \in \mathcal{H}_k$ bajo una condición de integrabilidad. Representa promedios de funciones en el RKHS.
MMD^2	Es la distancia cuadrática entre embeddings de distribuciones. La fórmula sesgada empírica incluye diagonales de las matrices de Gram.
Matriz H	$H = I - \mathbf{1}\mathbf{1}^\top / N$ centra vectores y matrices. Es simétrica e idempotente. Reutilizar H no significa definir varias matrices diferentes.
Alineamiento RKHS	El índice del punto 3.2 es un alineamiento centrado de kernels y, para kernels lineales escalares, es Pearson al cuadrado, por lo que pierde el signo.